

Predicción de abandono de jugadores

Player Churn Risk Prediction
Informe técnico final y resumen ejecutivo

Isaac Esquivel Ruiz
Gael Rodríguez Jiménez
Ingeniería en Desarrollo de Software
Tecnimilenio
29 de septiembre de 2026

Propósito de la entrega

Este informe integra el desarrollo completo del proyecto, desde la definición del problema y la exploración del dataset hasta la evaluación final, explicación, inferencia y condiciones de uso. El notebook ejecutado y sus artefactos contienen el detalle reproducible.

La evidencia respalda Random Forest ajustado con umbral 0.39 como prototipo académico para priorizar revisión de retención en jugadores con al menos dos sesiones. La evaluación sobre datos sintéticos no valida un despliegue productivo.

Resultado principal	Evidencia en prueba
F1	0.8542
Recall	82.83%
Abandonos detectados	82 de 99
Falsas alertas	11 en 274 jugadores

Resumen ejecutivo

El proyecto identifica riesgo de abandono entre jugadores que acumularon al menos dos sesiones. Su utilidad propuesta es priorizar una revisión de retención. La población de modelado contiene 1,823 jugadores de un conjunto sintético de 2,096 registros y 187 variables.

Random Forest ajustado, con umbral 0.39, obtuvo accuracy 89.78%, precision 88.17%, recall 82.83%, F1 0.8542 y ROC-AUC 0.9255 en 274 jugadores reservados para prueba. Detectó 82 de 99 abandonos, omitió 17 y produjo 11 falsas alertas. Las acciones de retención podrían alcanzar más casos que una referencia trivial, pero no se ha medido ahorro económico ni efecto causal de una intervención.

Los 93 jugadores señalados en prueba son candidatos a revisión humana. Se recomienda una demostración controlada, sin incentivos, sanciones o exclusiones automáticas. Antes de un uso real se requiere telemetría prospectiva, una definición temporal verificable de abandono, revisión de calibración, costos y capacidad del equipo. El monitoreo debe revisar calidad en cada lote, drift semanal y desempeño con etiquetas nuevas de forma mensual.

Mapa de la entrega

Archivo	Contenido
Player_Churn_Proyecto_Final.ipynb	Fases 1 y 2 ejecutadas, documentación y exportación
Informe_Final_Player_Churn.docx y PDF	Informe integrado y conclusiones
Presentacion_Final_Player_Churn.pptx	Síntesis para exposición
Player_Churn_Entrega_Completa.zip	Notebook, dataset, informe, presentación y artefactos de inferencia

Problema y datos

El abandono reduce la actividad de un videojuego y dificulta la retención. El proyecto formula una clasificación binaria supervisada a nivel jugador: `player_churn=1` representa abandono y 0 permanencia. Un equipo de analítica podría ordenar candidatos para revisión, sin asumir que una predicción demuestra la causa del abandono.

El criterio inicial fue superar la referencia mayoritaria y buscar recall de churn ≥ 0.70 en validación, considerando conjuntamente precisión, F1 y ROC-AUC. Se mantiene el mismo objetivo y dataset en ambas fases.

Elemento	Valor
Fuente declarada	AWS Player Churn sample dataset, sintético
Dataset original	2096 jugadores; 187 variables
Objetivo original	922 churn y 1174 permanencias
Población del modelo	1823 jugadores con al menos dos sesiones
Churn en población del modelo	655 jugadores; 35.93%
Exclusión de una sesión	273 jugadores; 267 con churn (97.80%)
Particiones	1276 train; 273 validación; 274 prueba
Semilla	42; particiones estratificadas

El filtro separa abandono tras la primera experiencia y abandono posterior. El modelo solo responde al segundo problema. En un sistema real, la elegibilidad de dos sesiones debe estar disponible antes de la predicción, no calcularse retrospectivamente a partir del futuro.

Diccionario y exploración

El notebook construye un diccionario para las 187 variables. Incluye identificación, cohortes, características del jugador, conteos de sesiones y stages, y estadísticas de horarios en varias ventanas. El EDA inspecciona distribuciones, asociaciones con churn, correlaciones y rangos. Menor permanencia y menor actividad aparecen asociadas a churn, sin constituir reglas causales.

Calidad y preprocesamiento

Problema	Evidencia	Tratamiento
Faltantes	11231 valores en 42 variables	Imputación mediana numérica y moda categórica
Duplicados	0 filas duplicadas; ID único	Verificación antes de modelar
Constantes	24 variables originales	VarianceThreshold ajustado en cada fold
Atípicos	Conteos y telemetría con colas	Conservar posibles; alertar extremos en inferencia
Categoría de cohorte	Día de la semana	One Hot Encoding; categoría desconocida se rechaza en inferencia

Se excluyen player_id por ser identificador, player_type por riesgo de codificar el generador sintético y cohort_id por artefactos de cohorte. El objetivo se separa de los predictores. Conservar cohort_day_of_week no elimina toda dependencia temporal, como muestra su importancia posterior.

En Fase 1 quedaron 159 predictores antes de transformar. En Fase 2 entran 183 columnas, se crean dos ratios, se codifica la cohorte y se eliminan constantes dentro del ajuste. RF utiliza 167 características transformadas. Esas cantidades describen etapas distintas del flujo.

La imputación y StandardScaler se aprenden solo en entrenamiento. OneHotEncoder ignora categorías desconocidas internamente, pero el contrato de entrada de la demostración las rechaza de forma explícita para exigir revisión. No se aplica transformación logarítmica ni agrupación de categorías raras: no se identificó una necesidad validada. Los outliers plausibles permanecen.

Cambios trazables

Variable	Tratamiento anterior	Tratamiento nuevo	Razón	Efecto
Constantes	Detectadas antes de split	VarianceThreshold en cada fold	Evitar aprendizaje global	167 transformadas en RF
Ratios	No presentes	Dos razones de actividad	Evaluar relaciones	2 nuevas antes de selección
Nulos	Mediana/moda	Mismo criterio dentro de folds	Reproducibilidad	Sin eliminar registros adicionales
Atípicos	Conservar posibles	Conservar y advertir en inferencia	No borrar perfiles plausibles	Sin recorte
Población	Dos o más sesiones	Sin cambio	Comparabilidad	1823 jugadores

Evolución y familias de modelos

La Fase 1 estableció calidad, EDA, particiones y referencias Dummy, logística y árbol. La Fase 2 conservó los jugadores y agregó dos razones de actividad, selección dentro de cada fold, RF, boosting y SVM, búsquedas de hiperparámetros y una comparación con cinco folds estratificados. Las constantes pasan a eliminarse dentro del pipeline. Los outliers físicamente posibles se conservan para no borrar perfiles reales de alta actividad. La imputación mediana limita la sensibilidad de la sustitución a extremos, pero StandardScaler no los elimina.

Random Forest: combina árboles entrenados sobre muestras bootstrap y subconjuntos de variables. Promediar reduce la variabilidad de un árbol aislado y permite interacciones no lineales. Puede sobreajustar si los árboles son demasiado profundos o las hojas muy pequeñas. Se eligieron 120 árboles, profundidad máxima 8, mínimo 2 observaciones por hoja y 50% de variables candidatas por división, sin ponderación de clases. El entrenamiento cuesta más que un árbol simple y el conjunto completo requiere métodos de interpretación global y local.

Gradient Boosting: añade árboles sucesivos que corrigen errores de la función de pérdida. La referencia usa 80 árboles de profundidad 2 y tasa de aprendizaje predeterminada 0.1. Puede capturar relaciones complejas, aunque acumular demasiados árboles aumenta costo y sobreajuste. No resultó finalista en la decisión original de Colab.

SVM: busca una separación con margen. C controla la penalización de errores: un C alto permite ajustarse más a entrenamiento; uno bajo aumenta regularización. El kernel lineal genera una frontera lineal y RBF permite fronteras curvas. Gamma grande crea influencia más local y puede sobreajustar. El escalamiento evita que una variable domine por sus unidades. La búsqueda eligió RBF, C=10 y gamma='scale'. La opción probability=True agrega estimación interna de probabilidades y costo de ajuste; esto no demuestra calibración externa.

No se añadió una red neuronal porque es opcional y las familias exigidas ya están cubiertas. Los tiempos registrados corresponden al equipo de ejecución y no son una garantía de servicio.

Ingeniería de características y validación

Nueva característica	Origen	Regla	Interpretación	Riesgo de fuga
recent_session_share	Conteos de sesiones del día y semana previos	día / semana; cero si denominador es cero	Concentración reciente de actividad	Bajo solo si ambas ventanas cierran antes de inferir
stages_per_session_week	Stages y sesiones de semana previa	stages / sesiones; cero si denominador es cero	Intensidad de avance por sesión	Igual condición temporal; sin usar el objetivo

Ambas variables describen relaciones y no causas. Si faltan sus entradas, el código produce cero mediante `fillna(0)`, por lo que conviene revisar este supuesto antes de usar datos reales.

Parámetro	Valor
Método	StratifiedKFold, shuffle=True
Particiones y repeticiones	5 folds, 1 repetición
Semilla	42
Métrica principal	F1 de churn
Secundarias	Accuracy, precision, recall, ROC-AUC, tiempos
Ámbito	Solo las 1,276 observaciones de entrenamiento
Validación externa	273 jugadores para decisión y umbral
Prueba reservada	274 jugadores para evaluación final

Los mismos folds permiten comparar modelos sobre observaciones equivalentes. Media y desviación entre folds describen variación de la muestra mejor que un único holdout, aunque no son un intervalo de confianza. Imputación, escala, codificación y selección se ajustan dentro del fold. El conjunto de prueba no guía búsquedas ni umbrales. La CV de la configuración ganadora puede ser optimista por reutilizar los folds de búsqueda, por eso se conservan validación y prueba.

Las referencias de Fase 1 usaban un único holdout. Sus métricas no deben confundirse con las medias CV posteriores. En la Fase 2 se reevalúan referencias sin ingeniería y versiones con ingeniería bajo el mismo protocolo. En Colab el F1 CV de logística pasa de 0.6714 a 0.6715 y el del árbol de 0.7759 a 0.7786: el aporte observado de los ratios es pequeño para estas familias. No se realizó una ablación específica de RF sin ratios, por lo que no se atribuye su mejora exclusivamente a las nuevas características.

Comparación de experimentos

La tabla muestra resultados de la reproducción de cierre. Los valores de calidad coinciden con el experimento original en las métricas principales; los tiempos dependen del entorno. Los modelos con sufijo base no incluyen las dos características nuevas. El registro experimentos.csv guarda ID, fecha, hash del dataset, pipeline, hiperparámetros, validación y resultados.

Modelo	F1	DE	Recall	Prec.	AUC	Train s	Infer. ms
Dummy_base	0.0000	0.0000	0.0000	0.0000	0.5000	0.025	0.028
Logistica_base	0.6714	0.0515	0.6351	0.7159	0.8402	0.038	0.030
Arbol_base	0.7759	0.0682	0.7465	0.8168	0.8699	0.046	0.030
Dummy	0.0000	0.0000	0.0000	0.0000	0.5000	0.026	0.032
Logistica	0.6715	0.0542	0.6395	0.7103	0.8405	0.042	0.034
Arbol	0.7786	0.0669	0.7421	0.8276	0.8732	0.050	0.038
RandomForest	0.8181	0.0366	0.7596	0.8911	0.9435	0.307	0.087
GradientBoosting	0.8172	0.0285	0.7531	0.8997	0.9290	0.650	0.039
SVM_lineal	0.6918	0.0496	0.6111	0.8093	0.8442	0.190	0.068
SVM_RBF	0.7074	0.0621	0.6853	0.7336	0.8667	0.265	0.191
RandomForest_30	0.5384	0.0289	0.4934	0.5966	0.7391	0.237	0.092
RandomForest_ajustado	0.8684	0.0309	0.8186	0.9279	0.9552	1.146	0.078
SVM_ajustada	0.8230	0.0233	0.7968	0.8533	0.9117	0.258	0.153

Train s es el promedio por fold. Inferencia expresa milisegundos por registro del lote e incluye preprocesamiento y cálculo de probabilidades/clase, no la latencia de un servicio. La selección conserva las configuraciones ganadoras originales. La búsqueda repetida se guarda para auditoría y no autoriza reelegir después de test.

Espacio de búsqueda

Modelo	Exploración	Configuración final
RF	8 de 72 combinaciones; 5 folds	120 árboles; profundidad 8; hoja mínima 2; max_features=0.5; class_weight=None
SVM	9 combinaciones; 5 folds	RBF; C=10; gamma=scale

Optimización y decisión final

RF exploró 8 configuraciones aleatorias de 72 posibles y SVM evaluó 9 combinaciones. Con cinco folds fueron 40 y 45 ajustes de CV, respectivamente, más el reajuste de cada búsqueda. En Colab las búsquedas duraron aproximadamente 53.38 y 29.62 segundos. Los CSV conservan cada ensayo, parámetros y métricas. El cierre congela las configuraciones originales para no rededidir tras test.

La selección SelectKBest con ANOVA conserva 30 variables dentro de cada fold. Frente a RF completo (167 características transformadas), el F1 CV cayó de 0.8181 a 0.5384 y el tiempo medio pasó de 0.713 a 1.365 segundos por fold en Colab. Se rechaza esa reducción: no compensa perder desempeño y tampoco aceleró esta ejecución. ANOVA evalúa asociaciones univariadas y puede descartar interacciones útiles para árboles. No se concluye que toda reducción sea perjudicial.

La matriz original ponderó recall 25%, precision 15%, F1 25%, ROC-AUC 15%, estabilidad 5%, interpretabilidad 5%, entrenamiento 5% e inferencia 5%. Suma 100%. Se priorizó detección y equilibrio, manteniendo criterios operativos. La escala es relativa a candidatos y los puntajes de interpretación son juicios estructurales, no mediciones objetivas de comprensión humana.

Criterio	Evidencia original	Conclusión
Desempeño	RF F1 CV 0.8684 frente a SVM 0.8230	RF lidera en promedio
Generalización	RF F1 validación 0.8235; prueba 0.8542	Prueba no muestra deterioro frente a validación
Errores	RF 17 FN y 11 FP; SVM 26 FN y 7 FP	RF detecta más abandonos a cambio de más alertas
Interpretabilidad	Permutación y sensibilidad local	Requiere explicación complementaria
Complejidad	120 árboles de profundidad máxima 8	Más costo que un árbol, viable en esta muestra
Operación	Pipeline y script recargados con predicciones iguales	Demostración reproducible
Riesgo	Dataset sintético y temporalidad no verificada	Solo prueba controlada con revisión humana

RF y SVM empataron en F1 de validación a sus umbrales, 0.8235. El puntaje ponderado original favoreció RF (0.8998 frente a 0.8274). La decisión no depende únicamente de la mejor métrica. El F1 CV usa la clasificación predeterminada, mientras validación y prueba usan umbrales operativos: su diferencia no es una estimación pura de sobreajuste.



En validación se revisaron 91 umbrales por finalista, de 0.05 a 0.95. Se eligió el mayor F1 sujeto a recall ≥ 0.70 . RF usa 0.39 y SVM 0.64. Bajar el umbral de RF suele aumentar detecciones y falsas alertas; el balance debe revisarse con costos reales y capacidad de atención. No se ha demostrado un ahorro monetario ni una probabilidad perfectamente calibrada.

Evaluación reservada

Finalista	Umbral	Accuracy	Precision	Recall	F1	AUC
RandomForest_ajustado	0.39	0.8978	0.8817	0.8283	0.8542	0.9255
SVM_ajustada	0.64	0.8796	0.9125	0.7374	0.8156	0.8892

RF produce 164 TN, 11 FP, 17 FN y 82 TP. SVM produce 168 TN, 7 FP, 26 FN y 73 TP. RF identifica nueve abandonos adicionales a cambio de cuatro falsas alertas más en esta muestra. El test confirma la utilidad exploratoria de la decisión original, sin volver a ajustar.

RF pasa de F1 0.8235 en validación a 0.8542 en prueba. SVM pasa de 0.8235 a 0.8156. La variación no demuestra por sí sola sobreajuste ni asegura generalización futura. La población de prueba es pequeña y sintética.




Curvas ROC y precision recall del conjunto de prueba. Fuente: ejecución del notebook final.

Errores e interpretación global

En prueba RF detecta 82 abandonos, omite 17, clasifica correctamente 164 permanencias y genera 11 falsas alertas. Los FN tienen mediana de 3 sesiones y player_lifetime 434,014.83; los FP, 2 sesiones y 193,639.59. La actividad del último día tiene mediana 1 en los cuatro tipos de resultado, así que esa variable aislada no distingue suficientemente los errores. Estas descripciones no prueban causalidad ni una regla universal. Una revisión futura debe estudiar etiquetado, ventanas temporales y perfiles escasos antes de cambiar el umbral.

La permutación identifica cohort_day_of_week como variable dominante (caída media de F1 0.3351), seguida de player_lifetime (0.1151). Esto describe dependencia predictiva, no efecto causal. La fuerte influencia de cohorte puede representar patrones del generador sintético o del muestreo. Variables correlacionadas pueden compartir importancia y solo tres repeticiones dan una estimación limitada. Se necesitan cohortes temporales nuevas antes de generalizar.



Explicaciones individuales

Para cada tipo de resultado se eligió un caso cercano al umbral, lo que permite examinar decisiones sensibles. La sustitución por mediana mide sensibilidad y no contribuciones aditivas. Delta positivo indica que el valor original elevó el score frente a la referencia; delta negativo, que lo redujo.

Caso TP con índice 213

Clase real 1, predicción 1, probabilidad 0.419431, umbral 0.39. Identificó un abandono. Revisar señales antes de intervenir.

Variable	Valor original	Mediana	Delta score
cohort_day_of_week	2.000	3.000	+0.0917
player_lifetime	623738.511	340785.026	-0.0553

Caso TN con índice 932

Clase real 0, predicción 0, probabilidad 0.388341, umbral 0.39. Clasificó permanencia. El score cercano al umbral requiere prudencia.

Variable	Valor original	Mediana	Delta score
cohort_day_of_week	4.000	3.000	-0.1949
end_stage_time_of_day_std_last_day(-5)	2177.179	0.000	+0.1177

Caso FP con índice 943

Clase real 0, predicción 1, probabilidad 0.438098, umbral 0.39. Generó falsa alerta. Revisar contexto para evitar intervención innecesaria.

Variable	Valor original	Mediana	Delta score
begin_stage_time_of_day_std_last_month(-1)	211087.434	134316.817	-0.1263
end_stage_time_of_day_std_last_month(-1)	211085.157	134316.456	-0.1083

Caso FN con índice 1591

Clase real 1, predicción 0, probabilidad 0.370607, umbral 0.39. Omitió un abandono. Revisar información ausente y sensibilidad al umbral.

Variable	Valor original	Mediana	Delta score
cohort_day_of_week	0.000	3.000	-0.4331
player_lifetime	238598.257	340785.026	+0.1625

Comparación por grupos

El análisis local sustituye una variable por la mediana de entrenamiento y mide el cambio de probabilidad. Delta positivo significa que el valor original elevó el score respecto a esa referencia; negativo significa que lo redujo. No es SHAP ni una descomposición aditiva y puede crear combinaciones poco realistas. La tabla adicional de cierre muestra TP, TN, FP y FN con sus factores de mayor sensibilidad y una interpretación por caso.

Grupo	n	Churn	Recall	FPR	FNR
2–3 sesiones	188	36.17%	83.82%	8.33%	16.18%
4 o más sesiones	86	36.05%	80.65%	1.82%	19.35%

La brecha de recall es 3.17 puntos y la de FPR 6.52 puntos. Las tasas de abandono son similares, pero tamaños y perfiles difieren. No hay evidencia suficiente para afirmar discriminación: son grupos de comportamiento y datos sintéticos, sin atributos demográficos para auditar equidad. Se propone ampliar muestras, revisar intervalos y causas de error, y vigilar la brecha de FNR antes de definir tratamientos distintos por grupo.

Medidas de revisión

Ampliar la muestra de cada grupo, examinar incertidumbre e investigar mecanismos de captura antes de cambiar políticas. No aplicar incentivos distintos solo por pertenecer a un grupo de sesiones. No hay atributos demográficos suficientes para una auditoría completa de equidad.

Registro de riesgos

Las probabilidades de riesgo de la tabla son valoraciones cualitativas propuestas, no frecuencias estimadas. Isaac Esquivel Ruiz supervisa la demostración. En un despliegue se debe designar un responsable de datos y un responsable de retención antes de habilitar intervenciones.

Riesgo	Causa	Consecuencia	Probabilidad	Impacto	Mitigación
Falsos negativos	Señales incompletas o umbral	Omitir jugadores que abandonan	Media	Alto	Revisar FN y recall con etiquetas nuevas
Falsos positivos	Perfiles semejantes	Contactos o incentivos innecesarios	Media	Medio	Revisión humana y límite de capacidad
Drift	Cambios de juego o cohortes	Pérdida de validez	Media	Alto	PSI y evaluación temporal
Datos incompletos	Fallas de telemetría	Scores poco fiables	Media	Alto	Validar esquema, alertar y corregir fuente
Uso automático	Confundir score con certeza	Decisiones injustificadas	Media	Alto	Restringir a apoyo y registrar revisión
Sesgo de grupos	Representación desigual	Diferencias de error	Media	Alto	Vigilar FPR/FNR con muestras suficientes
Fuga temporal	Agregados posteriores al evento	Desempeño inflado	No determinada	Alto	Validar ventanas y etiquetas antes del uso real
Artefacto incompatible	Otra versión o fuente insegura	Error o ejecución no confiable	Media	Alto	Versiones fijadas y artefactos propios

Usos permitidos: enseñanza, experimentación y revisión de riesgo. Usos no recomendados: sanciones, exclusión, pagos o incentivos automáticos, y aplicación a jugadores con una sola sesión. Suspender un lote ante esquema inválido, artefacto incompatible o temporalidad dudosa. Suspender intervenciones si no existen responsables o si la caída de desempeño cumple los criterios de la siguiente sección.

Serialización e inferencia

El paquete contiene `pipeline_churn.joblib`, `churn_features.py`, `predict_churn.py`, `metadata.json` y `requirements.txt`. El artefacto incluye preprocesamiento, modelo, umbral y codificación del objetivo. Joblib puede ejecutar código: solo deben cargarse archivos propios o confiables.

Para reproducir: ejecutar el notebook de arriba abajo con `player-churn.csv`. Para inferencia: instalar `requirements.txt`, conservar los archivos juntos y ejecutar `python predict_churn.py --input ejemplos_entrada.csv --output predicciones.csv`. La versión de scikit-learn debe coincidir con la registrada. Se generan cinco perfiles seleccionados del test, explícitamente simulados y no nuevos clientes reales. La recarga y el proceso independiente deben devolver las mismas probabilidades y clases.

El validador rechaza columnas faltantes/adicionales, tipos incorrectos, categorías desconocidas, conteos imposibles, infinitos y población no elegible. Los nulos imputables y extremos posibles generan advertencias. Un registro puede ser estructuralmente válido y aun así necesitar revisión.

Perfil	Score original	Clase	Uso humano propuesto
Bajo riesgo	0.010310	Permanece	Seguimiento habitual; no excluir de atención
Riesgo medio	0.491750	Churn	Revisar actividad y contexto antes de contactar
Alto riesgo	0.987067	Churn	Priorizar revisión, sin incentivo automático
Categoría poco frecuente	0.778222	Churn	Verificar representatividad de cohorte
Cercano al umbral	0.388341	Permanece	Tratar como caso sensible, no como certeza

Riesgo medio significa cercanía a score 0.5 para la demostración; no es un segmento calibrado. Los detalles de sesiones, cohorte y observaciones se exportan en la tabla de simulaciones.

Evidencia de funcionamiento

Las diez pruebas de entrada cumplen su resultado esperado. La recarga conserva probabilidades y el script ejecutado en un proceso independiente produce las mismas probabilidades y clases. El notebook registra las versiones reales del entorno que genera cada artefacto.

Monitoreo y actualización

Indicador	Frecuencia	Alerta propuesta	Acción y responsable
Faltantes	Cada lote	>5% o +5 puntos frente a train	Responsable de datos revisa captura
Categorías o esquema	Cada lote	Cualquier categoría nueva o esquema inválido	Aislar lote y validar contrato de datos
Rango y volumen	Cada lote	Extremos nuevos o volumen fuera de 50–150% de referencia	Datos investiga antes de procesar
Errores de entrada	Cada lote	>1%	Datos corrige fuente
PSI y tasa positiva	Semanal	PSI >0.20 o cambio de tasa >10 puntos	Analítica investiga drift
Recall y FNR	Mensual con etiquetas	Recall <0.70 en dos ventanas con ≥ 50 positivos	Analítica revisa umbral y reentrena si procede
Precision, F1 y AUC	Mensual con etiquetas	Caída absoluta >0.05 en dos ventanas suficientes	Analítica valida deterioro y calibración
FPR y brecha FNR	Mensual	FPR sube >0.05 o brecha FNR >0.15	Analítica audita perfiles y mitigación
Latencia y disponibilidad	Diaria	>2 veces latencia de referencia o caída del servicio	Operación suspende automatización y restaura
Versión activa	Cada carga	Versión inesperada o predicciones no reproducibles	Operación bloquea artefacto

Todos los umbrales operativos son propuestas que deben acordarse con el equipo. El PSI se simula con datos alterados artificialmente, por lo que no demuestra drift real ni concept drift. Sin etiquetas nuevas no se puede medir la degradación predictiva.

Recalibrar si scores y frecuencias observadas divergen con datos suficientes. Cambiar umbral solo en validación nueva y con costos/capacidad aprobados. Reentrenar ante drift persistente con etiquetas nuevas o cambios del videojuego. Si cambia la definición de abandono, suspender la versión y redefinir etiqueta y ventanas. Mantener la versión anterior hasta validar la nueva y registrar responsable, fecha, motivo y comparación. Una caída de disponibilidad obliga a revisión manual; no autoriza sustituir silenciosamente el modelo.

Trazabilidad final y ficha del modelo

El cierre genera trazabilidad_final.csv, registro_riesgos.csv, ficha_modelo.json, inventario_artefactos.csv y tablas explicativas. El hash del dataset, las particiones por ID, los experimentos y las versiones de biblioteca permiten reconstruir la ejecución. La fuente declarada en el avance es AWS Player Churn sample dataset. No se dispone de URL ni fecha original de consulta verificadas: no se inventan. La fecha de esta revisión es 29/09/2026.

La versión documental 2.1 conserva el modelo lógico 2.0 y su decisión original. En Colab se usó scikit-learn 1.6.1. Al ejecutar en otro entorno, el notebook guarda las versiones reales y el artefacto generado debe utilizar esas dependencias. Las conclusiones sustantivas se contrastan con los resultados originales; tiempos y puntuaciones operativas pueden variar.

La ficha identifica propósito, usuarios previstos, dataset sintético, objetivo player_churn, población de dos o más sesiones, métricas, umbral, limitaciones, riesgos, grupos, inferencia, plan de monitoreo, actualización y responsable. Se autoriza su uso como demostración académica y apoyo experimental supervisado. Una evaluación aleatoria de datos sintéticos no valida su uso prospectivo en producción.

Elemento	Registro de cierre
Modelo y versión	RandomForest_ajustado; modelo lógico 2.0; documentación 2.1
Umbral y objetivo	0.39; player_churn 1=abandono, 0=permanencia
Dataset	player-churn.csv; 2096 filas; 1823 modeladas
SHA256	0b603ceb390c695d82cf3266360b115014eabc6e0f51008f5a4e4debc7048d80
Fecha de reproducción	2026-09-30T01:38:38.280153+00:00
scikit-learn de artefacto	1.8.0
Usuarios	Estudiante, docente y analista en prueba controlada
Responsable	Isaac Esquivel Ruiz
Usos permitidos	Demostración, enseñanza y revisión experimental supervisada
Uso restringido	Sin decisiones automáticas ni producción sin validación real

Los archivos trazabilidad_final.csv e inventario_artefactos.csv complementan esta ficha con configuración, métricas, archivos, versiones y hashes. El diccionario completo se conserva en el notebook y como CSV del paquete.

Conclusiones personales

Considero que la principal evolución del proyecto fue pasar de comparar clasificadores a construir un flujo que también puede guardar el modelo, validar entradas, explicar resultados y registrar su operación. La selección de Random Forest se sustenta en validación cruzada, la matriz ponderada y su equilibrio entre detecciones y falsas alertas. En prueba identificó 82 de 99 abandonos, con F1 de 0.8542.

La reducción a 30 características mostró que simplificar no garantiza mejorar: en la ejecución original de Colab empeoró el desempeño y aumentó el tiempo medido. También reconozco que la importancia de cohorte y el carácter sintético de los datos limitan la generalización. Las explicaciones describen asociaciones y sensibilidad, sin demostrar causas del abandono.